

8

Системи пам'яті

- 8.1 Вступ
- 8.2 Система пам'яті
 - Аналіз продуктивності
- 8.3 Кеш
- 8.4 Віртуальна пам'ять
- 8.5 Підсумок
 - Епілог Вправи
 - Питання для співбесіди

8.1 ВСТУП

Продуктивність комп'ютерної системи залежить від системи пам'яті, а також від мікроархітектури процесора. У розділі 7 розглядалася ідеальна система пам'яті, доступ до якої можна було отримати за один такт. Однак це було б правдою лише для дуже маленької пам'яті або дуже повільного процесора! Ранні процесори були відносно повільними, тому пам'ять могла за ними встигати. Але швидкість процесорів зростала швидше, ніж швидкість пам'яті. Наразі пам'ять DRAM у 10–100 разів повільніша за процесори. Зростаючий розрив між швидкістю процесорів і пам'яті DRAM вимагає все більш досконалих систем пам'яті, щоб наблизитися до швидкості процесорів. У першій половині цього розділу розглядаються системи пам'яті та компроміси між швидкістю, ємністю та вартістю.

Процесор спілкується з системою пам'яті через *інтерфейс пам'яті*. На [рисунку 8.1](#) показано простий інтерфейс пам'яті, який використовується в нашому багатоцикловому процесорі RISC-V. Процесор надсилає адресу через шину *адреси* до системи пам'яті. Для читання *MemWrite* дорівнює 0, і пам'ять повертає дані на шині *ReadData*. Для запису *MemWrite* дорівнює 1, і процесор надсилає дані до пам'яті на шині *WriteData*.

Основні *питання* проектування систем пам'яті можна широко пояснити за допомогою метафори про книги в бібліотеці. Бібліотека містить багато книг на полицях. Якщо ви пишете курсову роботу про значення снів, ви можете піти до бібліотеки ¹ і взяти з полиці книгу Фрейда «Тлумачення снів» і принести її до своєї кабінки. Проглянувши її, ви можете покласти її назад і взяти книгу Юнга «Психологія несвідомого». Потім ви можете повернутися за іншим цитатою з «Тлумачення снів», а потім знову піти до стелажів за книгою Фрейда «Его та Ід». Досить скоро

¹ Ми усвідомлюємо, що через Інтернет використання бібліотек серед студентів коледжів різко скорочується. Але ми також віримо, що бібліотеки містять величезні скарби важко здобутих людських знань, які недоступні в електронному вигляді. Ми сподіваємося, що веб-пошук не витіснить повністю мистецтво бібліотечних досліджень.





Рисунок 8.1 Інтерфейс пам'яті



ви втомитеся ходити від свого робочого місця до стелажів. Якщо ви розумні, ви заощадите час, зберігаючи книги у своєму робочому місці, а не тягаючи їх туди-сюди. Крім того, коли ви дістаєте книгу Фрейда, ви можете також дістати кілька інших його книг з тієї ж полиці. Ця метафора підкреслює принцип, представлений у розділі 6.2.1, швидкого вирішення типових випадків. Зберігаючи книги, які ви нещодавно використовували або, ймовірно, будете використовувати в майбутньому, у своєму кабінеті, ви зменшуєте кількість трудомістких поїздок до книгосховища. Зокрема, ви використовуєте принципи *тимчасової* та *просторової локальності*. Тимчасова локальність означає, що якщо ви нещодавно використовували книгу, то, ймовірно, скоро будете використовувати її знову. Просторова локальність означає, що коли ви використовуєте одну конкретну книгу, ви, ймовірно, зацікавитесь іншими книгами на тій самій полиці.

Бібліотека сама прискорює звичайні випадки, використовуючи ці принципи локальності. Бібліотека не має ні полицного простору, ні бюджету, щоб вмістити всі книги світу. Натомість вона зберігає деякі рідше використовувані книги в глибокому сховищі в підвалі. Крім того, вона може мати угоду про міжбібліотечний обмін з сусідніми бібліотеками, щоб мати можливість пропонувати більше книг, ніж фізично має в наявності.

Таким чином, ви отримуєте переваги як великої колекції, так і швидкого доступу до найчастіше використовуваних книг завдяки ієрархічній системі зберігання. Найчастіше використовувані книги знаходяться у вашій шафі. Більша колекція знаходиться на полицях. А ще більша колекція доступна, за попереднім замовленням, у підвалі та інших бібліотеках. Аналогічно, системи пам'яті використовують ієрархічну систему зберігання для швидкого доступу до найчастіше використовуваних даних, при цьому зберігаючи можливість зберігати великі обсяги даних.

Підсистеми пам'яті, що використовуються для побудови цієї ієрархії, були представлені в розділі 5.5. Комп'ютерні пам'яті в основному побудовані з динамічної оперативної пам'яті (DRAM) і статичної оперативної пам'яті (SRAM). В ідеалі система пам'яті комп'ютера є швидкою, великою і дешевою. На практиці одна пам'ять має лише дві з цих трьох властивостей: вона або повільна, або мала, або дорога. Але комп'ютерні системи можуть наблизитися до ідеалу, поєднуючи швидку, малу і дешеву пам'ять із повільною, великою і дешевою пам'яттю. Швидка пам'ять зберігає найчастіше використовувані дані та інструкції, тому в середньому система пам'яті здається швидкою. Велика пам'ять зберігає решту даних та інструкцій, тому загальна ємність є великою. Поєднання двох дешевих пам'ятей коштує набагато дешевше, ніж одна велика швидка пам'ять. Ці принципи поширюються на використання всієї ієрархії пам'ятей із зростаючою ємністю та зменшеною швидкістю.






Рисунок 8.2 Розбіжність продуктивності процесора та пам'яті. Адаптовано з дозволу Хеннессі та Паттерсона, «Архітектура комп'ютера: Кількісний підхід, 5-те вид., Morgan Kaufmann, 2011

Пам'ятайте, що швидкість характеризується як затримкою, так і пропускною здатністю. Затримка пам'яті — це час, необхідний для доступу до першого байта інформації. Пропускна здатність — це кількість байтів на секунду, які можуть бути передані. Багато пам'ятей мають хорошу пропускну здатність, але велику затримку.

Комп'ютерна пам'ять зазвичай складається з мікросхем DRAM. У 2021 році типовий ПК мав *основну пам'ять*, що складалася з 8–32 Гб DRAM, а вартість DRAM становила приблизно 3 долари за гібібайт (Гб). Протягом останніх трьох десятиліть ціни на DRAM знижувалися на 15–25 % щороку, а ємність пам'яті зростала з такою ж швидкістю, тому загальна вартість пам'яті в ПК залишалася приблизно незмінною. На жаль, швидкість DRAM покращувалася лише на 7 % щороку, тоді як продуктивність процесора зростала на 25–50 % щороку, як показано на [рисунок 8.2](#). На графіку показано швидкість пам'яті (DRAM) і процесора з урахуванням швидкості 1980 року як базової. Приблизно в 1980 році швидкість процесора і пам'яті була однаковою. Однак з того часу продуктивність розійшлася, і пам'ять сильно відстала ².

DRAM міг йти в ногу з процесорами в 1970-х і на початку 1980-х років, але зараз він, на жаль, занадто повільний. Час доступу до DRAM на один-два порядки довше, ніж час циклу процесора (десятки наносекунд у порівнянні з менш ніж однією наносекундою). Пропускна здатність DRAM хороша, близько 30 Гб/с.

Щоб протидіяти цій тенденції, комп'ютери зберігають найчастіше використовувані інструкції та дані в більш швидкій, але меншій за обсягом пам'яті, яка називається *кеш-пам'яттю*. Кеш-пам'ять зазвичай побудована на базі SRAM на тому ж чіпі, що і процесор. Швидкість кеш-пам'яті порівнянна зі швидкістю процесора, оскільки SRAM за своєю суттю є швидшою за DRAM, а вбудована в чіп пам'ять усуває тривалі затримки, спричинені переміщенням даних до та з окремого чіпа.

² Хоча останнім часом продуктивність однопроцесорних систем залишається приблизно незмінною, як показано на [рисунок 8.2](#) за 2005–2010 роки, зростання кількості багатоядерних систем (не показано на графіку) тільки поглиблює розрив між продуктивністю процесорів і пам'яті.

У 2021 році вартість вбудованої SRAM становила близько 100 доларів за Гб, але кеш є відносно невеликим (від кібібайтів до декількох мебібайтів), тому загальна вартість є низькою. Кеш-пам'ять може зберігати як інструкції, так і дані, але ми будемо називати її вміст загальним терміном «дані». Затримка SRAM коливається від декількох десятків наносекунд для кеш-пам'яті розміром 16 КіБ до декількох наносекунд для кеш-пам'яті розміром 4 МІБ. Пропускна здатність може досягати сотень ГБ/с.

Якщо процесор запитує дані, які є в кеші, вони швидко повертаються. Це називається *кеш-попаданням*. В іншому випадку процесор отримує дані з основної пам'яті (DRAM). Це називається *кеш-промахом*. Якщо кеш-попадання відбуваються більшу частину часу, то процесор рідко доводиться чекати на повільну основну пам'ять, і середній час доступу є низьким.

Третім рівнем в ієрархії пам'яті є жорсткий диск. Так само, як бібліотека використовує підвал для зберігання книг, які не вміщаються на полицях, комп'ютерні системи використовують жорсткий диск для зберігання даних, які не вміщаються в основній пам'яті. У 2021 році жорсткий диск (HDD), побудований з використанням магнітного накопичувача, коштував менше 0,03 долара за Гб і мав час доступу приблизно від 5 до 10 мс. Пропускна здатність становить від 100 МБ/с для великих файлів до 1 МБ/с для випадкового доступу до невеликих (4 КБ) файлів. Вартість жорстких дисків знижувалася на 60% щороку, але час доступу майже не покращився. Твердотільні накопичувачі (SSD), побудовані з використанням технології флеш-пам'яті, стають все більш поширеною альтернативою HDD. SSD використовуються на нішевих ринках вже понад два десятиліття, а в 2007 році вони були представлені на основному ринку. SSD подолали деякі механічні недоліки HDD, але коштують у 3–4 рази дорожче — 0,10 долара за Гб. З моменту появи SSD на ринку різниця в ціні між ними та HDD зменшилася, а популярність SSD порівняно з HDD відповідно зросла. Час доступу SSD становить менше 0,1 мс. Пропускна здатність може становити від 500 до 3000 МБ/с для великих файлів і від 50 до 250 МБ/с для файлів розміром 4 КБ.

Жорсткий диск створює ілюзію більшої ємності, ніж насправді існує в основній пам'яті. Тому його називають *віртуальною пам'яттю*. Як і книги в підвалі, дані у віртуальній пам'яті вимагають багато часу для доступу. Основна пам'ять, яку також називають *фізичною пам'яттю*, містить підмножину віртуальної пам'яті. Отже, основну пам'ять можна розглядати як кеш для найбільш часто використовуваних даних з жорсткого диска.

На [рисунку 8.3](#) підсумовано ієрархію пам'яті комп'ютерної системи, яка розглядається в решті цього розділу. Процесор спочатку шукає дані в невеликому, але швидкому кеші, який зазвичай розташований на тому самому чіпі. Якщо




Рисунок 8.3 Типова ієрархія пам'яті




Рисунок 8.4 Компоненти ієрархії пам'яті з типовими характеристиками у 2021 році

Якщо дані відсутні в кеші, процесор шукає їх в основній пам'яті. Якщо даних немає і там, процесор отримує дані з віртуальної пам'яті на великому, але повільному жорсткому диску. На [рисунку 8.4](#) показано компроміс між ємністю та швидкістю в ієрархії пам'яті та наведено типові витрати, час доступу та пропускну здатність за технологією 2021 року. Зі зменшенням часу доступу швидкість збільшується.

У [розділі 8.2](#) представлено аналіз продуктивності системи пам'яті. У [розділі 8.3](#) розглянуто кілька типів організації кеш-пам'яті, а в [розділі 8.4](#) детально розглянуто системи віртуальної пам'яті.

8.2 АНАЛІЗ ПРОДУКТИВНОСТІ СИСТЕМИ ПАМ'ЯТІ

Розробники (та покупці комп'ютерів) потребують кількісних методів вимірювання продуктивності систем пам'яті, щоб оцінити співвідношення витрат і вигод різних альтернатив. Показниками продуктивності системи пам'яті є *частота промахів* або *частота влучень* і *середній час доступу до пам'яті*. Частота промахів і частота влучень обчислюються таким чином:

$$\begin{aligned} \text{Частота промахів} &= \frac{\text{Кількість промахів}}{\text{Кількість загальних звернень до пам'яті}} = 1 - \frac{\text{Кількість влучень}}{\text{Кількість загальних звернень до пам'яті}} \\ \text{Коефіцієнт влучності} &= \frac{\text{Кількість влучень}}{\text{Загальна кількість звернень до пам'яті}} = 1 - \text{Частота промахів} \end{aligned} \quad (8.1)$$

Приклад 8.1 РОЗРАХУНОК ПРОДУКТИВНОСТІ КЕШ-ПАМ'ЯТІ

Припустимо, що програма має 2000 інструкцій доступу до даних (завантаження або збереження) і 1250 із цих запитуваних значень даних знаходяться в кеші. Інші 750 значень даних подаються до процесора з основної пам'яті або дискової пам'яті. Які коефіцієнти промахів і влучень для кешу?

Розв'язання Частота промахів становить $750/2000 = 0,375 = 37,5\%$. Частота влучень становить $1250/2000 = 0,625 = 1 - 0,375 = 62,5\%$.