

Моделювання роботи препроцесора для попередньої обробки мовних сигналів

Методичні вказівки

до лабораторної роботи № 1 з дисципліни “Комп’ютерні засоби обробки
сигналів” для студентів спеціальності "Комп'ютерні системи та мережі"

Ужгород – 2024

Моделювання роботи препроцесора для попередньої обробки мовних сигналів

Мета роботи

Опрацювати та випробувати в середовищі MATLAB 6.0 програму, яка реалізує етапи попередньої обробки мовних зразків.

Вступні пояснення

Сучасні системи для розпізнавання суцільної мови з великим словником ґрунтуються на принципах статистичного розпізнавання образів [3,4]. На рис.1 показана структура типової системи статистичного розпізнавання, що включає чотири складових.




Рис.1 Структура системи розпізнавання мови

Складові виконують такі функції:

- звуковий препроцесор здійснює початковий етап обробки, на якому з мовного сигналу вибирається вся необхідна звукова інформація в компактному вигляді;
- звукова модель забезпечує обчислення правдоподібності будь-якої послідовності звукових векторів при заданій послідовності слів;
- модель мови забезпечує обчислення апіорної ймовірності послідовності слів незалежно від спостереження мовного сигналу. Для цього треба забезпечити механізм оцінки ймовірності певного слова у фразі, якщо знаємо попередні слова;
- класифікатор зводить воєдино дані від трьох раніше описаних компонент і знаходить найбільш імовірний текст (транскрипцію).

Принципи статистичного розпізнавання образів полягають у наступному [4].

На першому етапі мовний зразок перетворюється звуковим процесором на послідовність звукових векторів $Y = \vec{y}_1, \vec{y}_2, \dots, \vec{y}_T$. Кожен вектор є стислим поданням короткочасного мовного спектру на інтервалі, як правило, близько 25 мс зі зсувом інтервалів на 10 мс. Типова фраза з десяти слів по 6-7 звуків у кожному може мати тривалість біля 3 с і представлятися послідовністю з $T=300$ звукових векторів.

У загальному, фраза складається з послідовності слів $W = w_1, w_2, \dots, w_n$. Робота системи розпізнавання полягає у визначенні найбільш імовірної послідовності слів $\hat{W}$, маючи звуковий сигнал Y . Для цього використовується правило Байєса [4]:

$$\hat{W} = \arg \max_W P(W / Y) = \arg \max_W \frac{P(W)P(Y / W)}{P(Y)}.$$

Ця рівність показує, що для знаходження найбільш правдоподібної послідовності слів W , повинна бути знайдена послідовність, що робить максимальним добуток $P(W)$ та $P(Y/W)$. Так як значення знаменника $P(Y)$ не залежить від W , то його при розпізнаванні ігнорують.

Перший із співмножників є апіорною ймовірністю спостереження W незалежно від спостереження мовного сигналу. Ця ймовірність визначається моделлю мови.

Другий співмножник є ймовірністю спостереження послідовності векторів Y при заданій послідовності слів W . Ця ймовірність визначається звуковою моделлю.

В звуковій моделі послідовності слів розбиваються на базові звуки – фонemi. Кожна індивідуальна фонема представляється прихованою моделлю за Марковим (англійська назва – hidden Markov model (НММ)). НММ-модель фонemi, як правило, має три породжуючі стани та вхідний і вихідний стан. Вхідний і вихідний стани дозволяють моделям фонем об'єднуватися, щоб утворювати слова та об'єднувати слова для утворення речень (послідовності слів).

Розглянемо більш детально функції препроцесора для попередньої обробки мовних сигналів.

Звуковий препроцесор

Потрібен початковий етап обробки, на якому з мовного сигналу вибирається вся необхідна звукова інформація в компактному вигляді.

Принципове припущення, яке робиться в сучасних розпізнавачах [3,4] є те, що мовний сигнал розглядається як стаціонарний (тобто спектральні характеристики відносно постійні) на інтервалі в кілька десятків мілісекунд. Тому основною функцією попередньої обробки є розбиття вхідного мовного сигналу на інтервали [1 - 4] і отримання для кожного інтервалу згладженої спектральної оцінки. Зсув між інтервалами звичайно рівний 10 мс. Інтервали, як правило, перекриваються і мають тривалість 25 мс. Як звичайно для обробки такого типу до кожного інтервалу на початку застосовується функція вікна (наприклад, вікно Гемінга). Часто застосовують високочастотне підсилення, щоб компенсувати послаблення, спричинене розсіюванням звуку від губ.

Щоб отримати спектральні оцінки використовується швидке перетворення Фур'є.

Фур'є спектр згладжується додаванням спектральних коефіцієнтів у межах “трикутних” частотних смуг розташованих на нелінійній (подібній до логарифмічної) Mel-шкалі [4]. Для граничної частоти мови (16 КГц) беруть 24 таких частотних смуги. Mel-шкала введена для наближення частотного розділення людського вуха, яке є лінійним до 1000 Гц та логарифмічним понад 1000 Гц.

З метою зробити статистику оціненого спектру потужності мови близькою до Гауссової до виходів набору фільтрів застосовується логарифмічний стиск.

До прологарифмованих коефіцієнтів застосовують дискретне косинусне перетворення. Це зосереджує спектральну інформацію в кепстральних коефіцієнтах з малими номерами, а також декорелює їх, дозволяючи при наступному статистичному моделюванні використовувати діагональні коваріаційні матриці. Перші 12 кепстральних

коефіцієнтів та логарифм енергії інтервалу сигналу утворюють базовий 13-елементний звуковий вектор.

Є ряд додаткових перетворень, які можна застосувати для отримання остаточного звукового вектора.

Для зменшення мультиплікативного шуму на звукових векторах роблять нормалізацію кепстральних коефіцієнтів. Для кожної з дванадцяти компонент обчислюються середні значення по всіх звукових векторах даного мовного зразка. Ці середні значення віднімаються від відповідних компонент всіх звукових векторів даного мовного зразка.

Компоненти логарифму енергії даного мовного зразка, які менші від максимального значення на 50 дБ, замінюються на значення цього порогу. Потім всі значення логарифму енергії масштабуються так, щоб максимальне значення стає рівним 1,0.

Припускається, що кожен звуковий вектор не зв'язаний зі своїми сусідами. Це досить грубе припущення, бо фізичні обмеження голосового тракту людини передбачають плавні переходи між сусідніми спектральними оцінками. Проте додавання різниць та різниць різниць базових елементів значно пом'якшує припущення. Переважно для цього беруться два попередні та два наступні вектори. У результаті отримуємо 39-елементний вектор [4]. Кілька інших можливих варіантів отримання звукових векторів описано в [3].

Попередня обробка мовних зразків (реалізація звукового препроцесора) ISOLET

База даних ISOLET складається з 7800 мовних зразків окремо вимовлених звуків англійської мови. Два зразки кожного звуку були записані від 150 осіб. Зразки дискретизовані з частотою 16 КГц та мають розрядність 16. Середня тривалість зразків - 0,5 с.

Етапи попередньої обробки мовних зразків у базі даних ISOLET детально описані нижче.

1. Оцифрований (дискретизований за часом та квантований за рівнем) мовний сигнал розбиваємо на блоки по 25.6 мс із зсувом кожні 10 мс, тобто, блоки по 409 відліків кожен блок, із зсувом на 160 відліків.

2. Пропускаємо блоки через фільтр першого порядку

$$S'_n = \begin{cases} 0, & \text{.....якщо...} n = 1 \\ S_n - S_{n-1}, & \text{....у протилежному випадку} \end{cases},$$

де S_n – n -й відлік у блоці.

3. Застосовуємо до блоку вікно Гемінга згідно з виразом

$$S''_n = 0.54 - 0.46 \cos\left(\frac{2\pi(n-1)}{408}\right) S'_n \quad \text{для } n = 1, \dots, 409$$

4. Збільшуємо довжину блоку до 512 елементів за рахунок доповнення його вкінці потрібною кількістю нулів. Після цього застосовуємо дискретне перетворення Фур'є й отримуємо 256 спектральних комплексних значень.

5. Нульовий член ігноруємо, а величини решта 255 спектральних значень усереднюємо. Усереднення реалізуємо як 24 трикутні смугопропускні фільтри. Нижня, середня та верхня частоти подані в таблиці. Вони апроксимують Mel-шкалу згідно з формулою

$$g=2595 \log_{10}(1+ f / 700),$$

де g – частота в Mel, f – частота в Герцах.

Смуга	Нижня частота	Середня частота	Верхня частота
1	0,000 Гц	74,24 Гц	156,4 Гц
2	74,24 Гц	156,4 Гц	247,2 Гц
3	156,4 Гц	247,2 Гц	347,6 Гц
4	247,2 Гц	347,6 Гц	458,7 Гц
5	347,6 Гц	458,7 Гц	581,6 Гц
6	458,7 Гц	581,6 Гц	717,5 Гц
7	581,6 Гц	717,5 Гц	867,9 Гц
8	717,5 Гц	867,9 Гц	1034 Гц
9	867,9 Гц	1034 Гц	1218 Гц
10	1034 Гц	1218 Гц	1422 Гц
11	1218 Гц	1422 Гц	1647 Гц
12	1422 Гц	1647 Гц	1895 Гц
13	1647 Гц	1895 Гц	2171 Гц
14	1895 Гц	2171 Гц	2475 Гц
15	2171 Гц	2475 Гц	2812 Гц
16	2475 Гц	2812 Гц	3184 Гц
17	2812 Гц	3184 Гц	3596 Гц
18	3184 Гц	3596 Гц	4052 Гц
19	3596 Гц	4052 Гц	4556 Гц
20	4052 Гц	4556 Гц	5113 Гц
21	4556 Гц	5113 Гц	5730 Гц
22	5113 Гц	5730 Гц	6412 Гц
23	5730 Гц	6412 Гц	7166 Гц
24	6412 Гц	7166 Гц	8000 Гц

6. Логарифмуємо отримані 24 середні значення.

7. Обчислюємо перші 12 значень дискретного косинусного перетворення.

$$[O(u)_t]_i = \sum_{j=1}^{24} m_j \cos\left(\frac{\pi i(j-0,5)}{24}\right) \text{ для } i=1 \dots 12$$

де m_j - значення логарифму j -го середнього значення.

8. У кінець додаємо тринадцятий елемент, енергію поточного блока $\sum_{n=1}^{409} S_n^2$.

Далі можна обчислювати ще 26 елементів. Це ”різниця” та “різниця-різниць” коефіцієнти. 13 “дельт” $[O(u)_t]_{14}, \dots, [O(u)_t]_{26}$ апроксимують степінь зміни базових коефіцієнтів косинусного перетворення та енергетичних коефіцієнтів. Їх обчислюємо так:

$$[O(u)_t]_{i+13} = \begin{cases} [O(u)_{t+1}]_i - [O(u)_t]_i \dots \dots \dots \text{для } t = 1, 2 \\ \frac{\sum_{r=1}^2 r([O(u)_{t+r}]_i - [O(u)_{t-r}]_i)}{2 \sum_{r=1}^2 r^2} \dots \dots \dots \text{для } t = 3, \dots, T(u) - 2 \\ [O(u)_t]_i - [O(u)_{t-1}]_i \dots \dots \dots \text{для } t = T(u) - 1, T(u) \end{cases}$$

13 “дельта-дельт” $[O(u)_t]_{27}, \dots, [O(u)_t]_{39}$, які апроксимують прискорення базових коефіцієнтів косинусного перетворення Фур’є та енергетичних коефіцієнтів, отримуємо за наведеною вище формулою.

Кожний логарифмічний енергетичний профіль запису скануємо і низькочастотні значення заміняємо значенням на 50дБ нижче пікового значення. Потім енергетичний профіль масштабуємо так, щоб пікове значення було 1.0.

Зразок програми на мові сценаріїв MATLAB 6.0

Далі наведено зразок програми на мові сценаріїв MATLAB 6.0, яка реалізує описані вище етапи 1-5 попередньої обробки мовних зразків у базі даних ISOLET.

```
clear all;
vybirka = 1 ;
signal = wavread('example.wav') ;
subplot(3,3,1); plot(signal); title('example.wav');
d = length(signal) ;
i = 1 ;
while i < d - 408
    vybirka = vybirka + 1 ;
    y = signal(i : i + 408) ;
    S(1) = 0.0 ;
    for n = 2 : 409
        S(n) = y(n) - y(n - 1) ;
    end;
    for n = 1 : 409
        D(n) = (0.54 - 0.46 * cos(2 * pi * (n - 1) / 408)) * S(n) ;
    end;
    B = abs(fft(D , 512)) ;
    C = B(1:256);

    Hz = [0; 74.24; 156.4; 247.2; 347.6; 458.7; 531.6; 717.5; 867.9 ; 1034;
1213; 1422; 1647; 1895; 2171;
2475; 2812; 3184; 3596; 4052; 4556; 5113; 5730; 6412; 7166; 8000];
    for n = 1 : 26
        V(n) = round (Hz(n) * 256 / 8000) ;
        V(1) = 1;
```

```


end;
Sum = 0 ;
R(1 : 24) = 0;
for j = 1 : 24
    N = V(j + 2) - V(j);
    N1 = V(j + 1) - V(j);
    D1 = 1 / N1;
    for k = 1 : N1
        Sum = Sum - S(k + V(j)) * D1 * k;
    end;
    N2 = V(j + 2) - V(j + 1);
    D2 = 1 / N2;
    for k = 1 : N2
        Sum = Sum - S(k + V(j + 1)) * (1 - D2 * k) ;
    end;
    R(j) = Sum / N ;
    Result (vybirka,j) = R(j);
end;
i = i + 160;
end;
subplot(3,3,2); plot(y);title('          409 values ');
subplot(3,3,3); plot(S);title('          applying filters');
subplot(3,3,4); plot(D);title('          Hemming');
subplot(3,3,5); plot(B);title('          512 fft ');
subplot(3,3,6); plot(C);title('          256 elements ');
subplot(3,3,7); plot(Result(vybirka,1:24));
title('          24-element vector');

```

Типовий мовний зразок, який обробляємо – звуковий файл example з розширенням wav (затягнутий звук ‘о’). Файли цього типу можна створювати, редагувати та прослуховувати за допомогою звукової плати, мікрофона й навушників у середовищі професійного звукового редактора Cool Edit. Вигляд вікна цього звукового редактора показано нижче.



Графічне вікно середовища MATLAB 6.0, у якому ілюструються етапи попередньої обробки мовного зразка example.wav згідно з наведеною програмою, показано далі.



Зміст звіту

1. Мета роботи.
2. Основні теоретичні відомості.
3. Блок-схема алгоритму попередньої обробки мовного сигналу.
4. Результат виконання індивідуального завдання
 - а) скоректована програма на мові на мові сценаріїв MATLAB 6.0, яка реалізує етапи попередньої обробки мовного сигналу;
 - б) спектральні вектори, які є результатом опрацювання заданого викладачем мовного сигналу. (записаний мовний сигнал «Я, Ім'я, Прізвище Студент Ужгородського національного університету інженерно-технічний факультет, група KI-41»)
5. Висновок.

ЛІТЕРАТУРА

1. Бабак В.П., Хандецкий А.І., Шрюфер Е. Обробка сигналів: підручник для вузів., К., Либідь, 1996.- 390с.
2. Бондарев В.Н., Трестер Г., Чернега В.С. Цифровая обработка сигналов: методы и средства. - Харьков: Конус, 2001 (підручник для вузів).
3. Винцюк Т.К. Анализ, распознавание и интерпретация речевых сигналов.-К., Наукова думка,1987.-264с.
 4. Young S. Large vocabulary continuous speech recognition. IEEE Signal Processing Magazine, 13(5), 1996, pp.45-57.